

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ - ĐHQGHN
VIỆN TRÍ TUỆ NHÂN TẠO



MÔN HỌC: LẬP TRÌNH XỬ LÝ DỮ LIỆU

CHỦ ĐỀ: NYC TLC Taxi Trips

Chuẩn hóa hành trình & tổng hợp theo thời gian/ khu vực

BÁO CÁO KỸ THUẬT

Thông tin cơ bản

Hạng mục	Thông tin chi tiết
Tên nhóm	Group 1.4
Năm dữ liệu	2022
Thành viên	Quách Lê Hồng Ngọc - 24022419 Chu Việt Hà - 24022315 Phạm Công Thành - 24022455
Ngày nộp	19/12/2025
Commit Hash	4622a37

I. GIỚI THIỆU & TỔNG QUAN DỮ LIỆU

1. Nguồn dữ liệu

Dữ liệu được thu thập từ NYC Taxi & Limousine Commission (TLC), cơ quan quản lý phương tiện vận tải công cộng tại New York. Đây là bộ dữ liệu mở uy tín ghi lại lịch sử các chuyến đi của yellow taxi.

2. Phạm vi dữ liệu

- Thời gian: Từ ngày 01/01/2022 đến ngày 31/12/2022.
- Không gian: Toàn bộ các khu vực (Zones) và quận (Boroughs) thuộc thành phố New York.
- Định dạng: 12 tệp Parquet (tương ứng 12 tháng) và 1 tệp tra cứu khu vực (CSV).

3. Đặc điểm chính

Dữ liệu bao gồm các trường thông tin quan trọng: Thời gian đón/trả (pickup/dropoff_datetime), Số lượng hành khách, Quãng đường (trip_distance), Mã vùng đón/trả (PULocationID/DOLocationID), Chi tiết giá cước (Fare, Tip, Tolls, Total Amount) và Hình thức thanh toán.

II. LÀM SẠCH & CHUẨN HÓA

Để đảm bảo kết quả phân tích chính xác, nhóm đã xây dựng bộ quy tắc kiểm soát chất lượng (QA Rules) và xử lý dữ liệu như sau:

1. Quy tắc QA và Tác động

Dựa trên thống kê lỗi (QA Summary), chúng tôi đã xử lý các vấn đề nổi bật:

- Dữ liệu lỗi logic:
 - Loại bỏ 574,059 bản ghi có quãng đường $\text{trip_distance} \leq 0$.
 - Loại bỏ 262,015 bản ghi có tổng tiền $\text{total_amount} \leq 0$ hoặc giá cước âm.
 - Tác động: Việc này giúp loại bỏ các chuyến đi bị hủy hoặc lỗi hệ thống, đảm bảo giá trị trung bình (Mean) không bị sai lệch.
- Dữ liệu ngoại lai (Outliers):
 - Loại bỏ 49,250 chuyến đi có tốc độ trung bình > 80 mph (phi thực tế trong đô thị).
 - Loại bỏ 46,979 chuyến đi kéo dài > 6 giờ (có thể do quên tắt đồng hồ).
 - Tác động: Biểu đồ phân phối thời gian và tốc độ trở nên mượt mà, phản ánh đúng hành vi di chuyển thực tế.

- Cảnh báo khác: Ghi nhận khoảng 11.7 triệu dòng có cảnh báo fare_component_mismatch (lệch thành phần giá), tuy nhiên nhóm quyết định giữ lại để phân tích tổng doanh thu thực tế thu được.

2. Chuẩn hóa danh mục & Thời gian

- Thời gian: Chuyển đổi định dạng chuỗi sang datetime, trích xuất thêm các đặc trưng: Giờ trong ngày (hour), Thứ trong tuần (day_of_week), Tháng (month).
- Danh mục: Ánh xạ PULocationID với bảng taxi_zone_lookup để chuyển đổi từ mã số sang tên địa danh cụ thể (ví dụ: ID 132 -> JFK Airport)

III. TỔNG HỢP & KPI

1. Định nghĩa và công thức

KPI	Định nghĩa	Công thức	Đơn vị
Total Trips	Tổng nhu cầu đi lại	Count(rows)	Chuyến
Total Revenue	Tổng doanh thu toàn thị trường	Sum(total_amount)	USD
Avg Trip Price	Giá trung bình mỗi chuyến	Total Revenue / Total Trips	USD
Avg Speed (p50)	Tốc độ di chuyển trung vị	Median(Distance / Duration)	mph
Duration (p95)	Thời gian di chuyển (Mức trần 95%)	Percentile(Duration, 95)	Phút

2. Bảng tổng hợp kết quả (So sánh Đầu năm vs. Cuối năm)

Số liệu trích xuất từ bảng KPI theo tháng:


Chỉ số	Tháng 01/2022	Tháng 12/2022	Thay đổi (%)
--------	---------------	---------------	--------------

Tổng số chuyến	1,661,338	2,328,170	+40.1%
Tổng doanh thu	\$31,607,010.10	\$58,319,105.15	+84.5%
Giá TB/ chuyến	\$19.02	\$25,05	+31.7%
Tốc độ (p50)	11.26 mph	10.00 mph	-11,2%

IV. TRỰC QUAN HÓA

Nhóm sử dụng thư viện Matplotlib để trực quan hóa 5 khía cạnh chính:

Hình 1: Xu hướng phục hồi doanh thu và sản lượng theo tháng



Doanh thu tăng 84.5% có phải chỉ do số chuyến tăng hay còn do chính sách tăng giá cước vào cuối năm?

- Mô tả: Biểu đồ kết hợp giữa cột (số chuyến) và đường (doanh thu) từ tháng 1 đến tháng 12/2022.

- Phân tích:


+ Dữ liệu cho thấy sự phục hồi mạnh mẽ của ngành vận tải sau đại dịch. Số lượng chuyến đi tăng trưởng ổn định, đạt đỉnh vào tháng 12 với mức tăng 40.1% so với tháng 1.

+ Đáng chú ý, doanh thu tăng trưởng nhanh hơn sản lượng (tăng 84.5%), cho thấy sự tác động của việc điều chỉnh giá cước và các phụ phí xăng dầu trong năm 2022.

=> Kết luận: Thị trường Taxi NYC đã vượt qua giai đoạn đóng băng và đang quay lại quỹ đạo tăng trưởng nóng.

Hình 2: Top 10 khu vực đón khách nhộn nhịp nhất

Nhu cầu tập trung cao độ tại Manhattan (Upper East Side, Midtown) và sân bay JFK.



- Mô tả: Biểu đồ cột ngang thể hiện 10 địa điểm có lượng PickupID lớn nhất.

- Phân tích:


+ Các khu vực như Upper East Side South, Midtown Center và Sân bay JFK luôn nằm trong top đầu.

+ Đặc biệt, lưu lượng tại sân bay JFK có tính ổn định rất cao và giá trị mỗi chuyến đi (Avg Fare) thường cao hơn hẳn so với nội đô.

- Ý nghĩa: Phân tích này giúp định hướng cho các hãng xe trong việc thiết lập các điểm dừng đỗ chiến lược.

Hình 3: Tốc độ di chuyển trung bình theo giờ


Tốc độ giảm mạnh xuống 9-10 mph vào khung giờ hành chính (8h-18h) do đường và tắc cao vào ban đêm.



- Mô tả: Biểu đồ đường thể hiện tốc độ trung bình (mph) thay đổi trong ngày.
- Phân tích:
 - + Tốc độ đạt mức cao nhất vào lúc 4:00 - 5:00 sáng (~18 mph) khi đường phố thông thoáng.
 - + Tốc độ giảm sâu xuống mức cực tiểu (~9 mph) trong khoảng 15:00 - 18:00. Điều này chứng tỏ sự tắc nghẽn giao thông nghiêm trọng tại Manhattan vào giờ cao điểm chiều.
- Kết luận: Hiệu suất vận hành tỷ lệ nghịch với nhu cầu. Việc di chuyển vào giờ cao điểm tốn thời gian gấp đôi so với ban đêm.

Hình 4: Thời gian di chuyển (p95) theo Thứ trong tuần.

Thứ Năm là ngày có thời gian di chuyển dài nhất (44.1 phút), phản ánh áp lực giao thông lớn nhất trong tuần.



- Mô tả: Biểu đồ cột thể hiện thời lượng chuyến đi ở bách phân vị thứ 95 (P95) theo các ngày trong tuần trong năm 2022.

- Phân tích:


+ Nhóm ghi nhận thời lượng chuyến đi đạt mức cao nhất vào Thứ Năm và Thứ Sáu (vượt ngưỡng 40 phút). Đây là thời điểm mật độ giao thông tăng cao nhất trong tuần, khiến các chuyến đi bị kéo dài.

+ Vào Thứ Bảy, thời lượng P95 có xu hướng giảm xuống mức thấp nhất. Điều này cho thấy sự thông thoáng hơn về giao thông hoặc các lộ trình di chuyển ngắn hơn so với ngày đi làm.

- Ý nghĩa: Chỉ số P95 giúp xác định giới hạn thời gian mà hầu hết các chuyến đi sẽ hoàn thành. Dữ liệu này giúp khách hàng và tài xế dự phòng thời gian di chuyển hợp lý, đặc biệt là vào các ngày cao điểm cuối tuần làm việc.

Hình 5: Biểu đồ nhiệt (Heatmap) mật độ chuyến đi

Vùng “nóng” nhất (đậm màu nhất) tập trung vào 17h -20h các ngày trong tuần.



- Mô tả: Heatmap thể hiện cường độ các chuyến đi theo 24 giờ và 7 ngày trong tuần.

- Phân tích:

+ Nhóm phát hiện "khung giờ vàng" tập trung từ 17:00 đến 20:00 các ngày từ Thứ Ba đến Thứ Sáu. Đây là thời điểm tan sở kết hợp với nhu cầu giải trí buổi tối.

+ Vào cuối tuần (Thứ Bảy, Chủ Nhật), nhu cầu dịch chuyển sang khung giờ muộn hơn (từ 19:00 đến 22:00) và tập trung nhiều ở các khu vực vui chơi.

- Ý nghĩa: Tài xế có thể dựa vào biểu đồ này để tối ưu hóa thời gian hoạt động, tập trung vào các "điểm nóng" thời gian để giảm thời gian chờ khách.

V. CÁC PHÂN TÍCH NÂNG CAO

1. Dự đoán nhu cầu Taxi:

a. Đặt vấn đề:

"Sau khi đã làm sạch và phân tích dữ liệu quá khứ, bước tiếp quan trọng tiếp theo là khả năng dự báo tương lai. Việc dự đoán chính xác nhu cầu taxi (Total Trips) không chỉ giúp tối ưu hóa vận hành mà còn hỗ trợ ra quyết định chiến lược về phân bổ tài nguyên."

b. Phương pháp: Sử dụng hai phương pháp khác nhau về độ phức tạp và cơ chế hoạt động

- Mô hình trung bình trượt đơn giản (SMA- Baseline):

- + Cơ chế hoạt động: Dự đoán nhu cầu bằng cách sử dụng dữ liệu của ngày cùng thứ trong tuần với khung quan sát là 3 tuần

- + Mục đích: Là phương pháp thống kê mô tả đơn giản, giả định rằng nhu cầu tương lai sẽ dao động quanh mức trung bình của quá khứ gần nhất

- Mô hình SARIMA:

- + Cơ chế hoạt động: Sử dụng mô hình Seasonal AutoRegressive Integrated Moving Average

- + Mục đích: Dự đoán dựa trên Xu hướng (Sự tăng/giảm dài hạn), Tính mùa vụ (Chu kỳ lặp lại hàng tuần), Tự hồi quy (Sự phụ thuộc của hiện tại vào các giá trị quá khứ) của dữ liệu phân tích

c. So sánh mô hình

- * Về mô hình trung bình trượt đơn giản (SMA – Baseline):

- Ưu điểm:

- + Tính ổn định: làm mượt các biến động nhiễu, giúp nhìn rõ xu hướng chung của dữ liệu

- + Dễ giải thích: Nguyên lý lấy trung bình cộng của quá khứ

- + Chi phí tính toán thấp: Chạy cực nhanh, không cần tối ưu tham số phức tạp

- Nhược điểm:

- + Độ trễ: Phản ứng chậm hơn so với thực tế, khi xu hướng thay đổi đột biến sẽ không thể phản ứng ngay lập tức mà cần thời gian

+ Mùa vụ: dữ liệu của mọi ngày được xử lí như nhau, không phân biệt ngày thường hay cuối tuần

+ Trọng số: Dữ liệu của 3 tuần trước được coi là quan trọng bằng dữ liệu của hôm qua

* Về mô hình SARIMA:

- Ưu điểm:

+ Xử lý tính mùa vụ: Nhờ bộ tham số mùa vụ (P,D,Q)_S, SARIMA hiểu rõ quy luật tuần hoàn 7 ngày

+ Tận dụng quán tính: Nhờ tham số p, mô hình nắm bắt được xu hướng, đà tăng/giảm của chuỗi số liệu

+ Khả năng tự sửa lỗi: Cơ chế Moving Average cho phép mô hình học từ sai số của quá khứ để tinh chỉnh dự báo tiếp theo

+ Khoảng tin cậy: Cung cấp thêm vùng rủi ro giúp đưa ra quyết định khi biết biên độ dao động an toàn

- Nhược điểm:

+ Độ phức tạp cao: Mô hình có tối ưu hay không dựa vào việc tìm và lựa chọn bộ tham số, nếu làm thủ công sẽ tốn rất nhiều thời gian và yêu cầu kiến thức chuyên môn cùng với kinh nghiệm

+ Tích lũy sai số: Nếu dự báo dài hạn (Giống trường hợp đầu ~10.65%), sai số sẽ bị cộng dồn theo thời gian (tức càng dự báo xa sai số càng lớn).

+ Nhạy cảm với cá điểm dị biệt (Các biến ngoại sinh): Khi mô hình không được cài đặt các biến ngoại lai như các ngày lễ hay sự kiện bất thường, sai số sẽ rất cao

Tiêu chí	SMA	SARIMA
----------	-----	--------

Độ phức tạp	Thấp (Dễ cài đặt)	Cao (Cần tối ưu tham số)
Cơ chế hoạt động	Trung bình cộng đều	Tự hồi quy & Tích hợp mùa vụ
Xử lý Mùa vụ	Kém (Không nhận biết chu kỳ)	Tốt (Bắt được nhịp tuần)
Độ trễ	Cao (Luôn đi sau xu hướng)	Thấp (Bám sát thực tế)
Sai số	~ 7.28%	~ 5.29% (Đã tối ưu)
Phù hợp nhất	Nhìn xu hướng dài hạn	Dự báo vận hành hàng ngày

d. Kết luận

"Kết quả thực nghiệm cho thấy sự vượt trội của mô hình SARIMA kết hợp chiến thuật Rolling Forecast với MAPE 5.29% so với mức 7.28% của mô hình trung bình trượt.

Điều này khẳng định rằng: Với dữ liệu có tính chu kỳ cao và chịu ảnh hưởng bởi các yếu tố ngoại sinh (Lễ, Tết) như Taxi, việc sử dụng mô hình tĩnh là không đủ. Cơ chế cập nhật dữ liệu hàng ngày (Rolling Update) là yếu tố sống còn để triệt tiêu sai số tích lũy, biến SARIMA từ một mô hình lý thuyết trở thành công cụ dự báo có tính ứng dụng thực tiễn cao."

2. Phát hiện bất thường:

a. Mục tiêu và Đặt vấn đề:

Trong dữ liệu Taxi, các ngưỡng lọc tĩnh thông thường không thể phân biệt được các yếu tố ngoại cảnh. Ví dụ: một chuyến đi kéo dài 60 phút có thể là bình thường vào giờ cao điểm Thứ Sáu, nhưng lại là bất thường nếu xảy ra vào lúc 3 giờ sáng Thứ Hai. Nhóm triển khai phương pháp Contextual Z-Score nhằm phát hiện các

điểm dị biệt dựa trên bối cảnh thời gian cụ thể, giúp làm sạch dữ liệu ở tầng sâu hơn.

b. Phương pháp thực hiện Nhóm xây dựng thuật toán phân tích dựa trên sự kết hợp giữa Giờ trong ngày (Hour) và Thứ trong tuần (Day of Week):

- Phân cụm bối cảnh: Chia dữ liệu thành 168 nhóm bối cảnh tương ứng với 24 giờ $\times$ 7 ngày.

- Tính toán chỉ số: Với mỗi chuyến đi, thuật toán tính toán độ lệch (Z-score) của Thời lượng (Duration) và Tốc độ (Speed) dựa trên giá trị trung bình và độ lệch chuẩn của chính nhóm bối cảnh đó.

- Ngưỡng xác định: Nhóm thiết lập ngưỡng $|Z| > 3$ để đánh dấu các chuyến đi là điểm dị biệt (Outliers).

c. Kết quả và Phân loại dị biệt Dựa trên kết quả thực nghiệm từ mã nguồn:

- Dị biệt về Thời lượng (Duration):

- + Quá dài ($Z > 3$): Thường do tài xế quên tắt đồng hồ sau khi kết thúc hành trình.

- + Quá ngắn ($Z < -3$): Do lỗi hệ thống hoặc chuyến đi bị hủy ngay lập tức.

- Dị biệt về Tốc độ (Speed):

- + Quá nhanh: Vượt xa trung bình khung giờ, thường do dữ liệu nhiễu về quãng đường.

- + Quá chậm: Các ca có $Z < -5$, phản ánh sự cố giao thông cực đoạn hoặc xe dừng chờ quá lâu nhưng vẫn để đồng hồ chạy.

d. Diễn giải ca điển hình (Extreme Case Example)

Qua phân tích, nhóm ghi nhận các trường hợp cực đoạn có chỉ số Z-Score Speed < -5 . Đây là những chuyến đi có tốc độ di chuyển thấp hơn rất nhiều so với vận tốc trung bình của bối cảnh thực tế (ví dụ: chỉ đạt 1-2 mph trong khi trung bình bối cảnh là 15-20 mph).

cảnh là 12 mph). Việc xử lý các ca này giúp các chỉ số hiệu suất vận hành (KPI Speed) không bị sai lệch bởi các yếu tố cá biệt.

VI. DIỄN GIẢI & KẾT LUẬN

1. Phát hiện chính

- Sự phục hồi mạnh mẽ: Năm 2022 đánh dấu sự hồi sinh của ngành taxi NYC sau đại dịch. Doanh thu tháng 12 tăng tới 84.5% so với tháng 1.
- Tương quan nghịch Tốc độ - Nhu cầu: Dữ liệu chứng minh rõ ràng: Khi nhu cầu tăng cao vào cuối năm hoặc giờ cao điểm, tốc độ di chuyển giảm đi đáng kể (chỉ còn 10 mph)
- Hành vi chi tiêu: Giá cước trung bình tăng 31.7% (lên mức \$25.05/ chuyến) nhưng nhu cầu vẫn tăng, cho thấy khách hàng chấp nhận chi trả cao hơn trong bối cảnh lạm phát.

2. Bối cảnh năm 2022

- Dịch bệnh: Sự sụt giảm mạnh đầu năm trùng khớp với làn sóng biến chủng Omicron
- Kinh tế: Giá cước tăng phản ánh chính sách điều chỉnh giá của thành phố trước tình hình giá xăng dầu và lạm phát năm 2022

3. Giới hạn

- Thiếu dữ liệu tiền Tip của các chuyến đi trả tiền mặt, do đó thu nhập thực tế của tài xế có thể cao hơn con số báo cáo khoảng 5-10%.
- Chưa phân tích sâu ảnh hưởng của thời tiết lên nhu cầu.

4. Đề xuất

- Vận hành: Tài xế nên tập trung vào khung giờ 17h- 20h để tối ưu doanh thu.
- Phân tích: Xây dựng thêm KPI "**Revenue per Hour**" để đánh giá hiệu quả thực tế khi phải di chuyển chậm trong giờ tắc đường.

VII. TÀI LIỆU THAM KHẢO

1. **Dữ liệu: NYC TLC Record Data:** Dữ liệu chuyến đi của Yellow Taxi năm 2022 được trích xuất từ trang chủ của <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>
2. **Thư viện Python:**

- Xử lý dữ liệu: pandas, numpy
- Định dạng tệp: pyarrow, fastparquet .
- Trực quan hóa: matplotlib.pyplot, seaborn
- Mô hình dự báo: pmdarima (Auto-ARIMA), statsmodels
- Đánh giá: sklearn.metrics

3. Tài liệu học tập: Bài giảng môn Lập trình xử lý dữ liệu, Geeksforgeeks